



**UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO**

---

**FACULTAD DE INGENIERÍA**

**Detección de ironía en textos  
cortos usando redes  
neuronales**

**TESIS**

Que para obtener el título de

**Licenciado en ingeniería en  
computación**

**P R E S E N T A**

Max Armando Sánchez Hernández

**DIRECTOR DE TESIS**

Dr. Iván Vladimir Meza Ruiz



**Ciudad Universitaria, Cd. Mx., 2019**

# Agradecimientos

Agradezco a los involucrados en la realización de esta tesis, a mi tutor Dr. Ivan Vladimir Meza Ruiz, a la Facultad de Ingeniería por la preparación que me dio, a la UNAM por darme la oportunidad de demostrar que puedo realizar mis sueños a base de esfuerzo y dedicación. A mi familia que me apoyó incondicionalmente. A mi hermana Ade que siempre supo que decir para animarme. A mi mamá por criarme y dotarme de criterio propio, por su preocupación que siempre me motivó a no dar el mínimo. A mi padre por ser un bastión de apoyo siempre. A mi hermano Juan por ser un modelo a seguir. A mi amiga Diana por ser siempre la compañera incondicional que cualquier persona podría desear. A los errores y caídas que sufrí hasta el momento ya que sin ellas no hubiera aprendido que lo valioso cuesta sudor, lágrimas y sangre, que no hay camino recto al éxito.

Agradezco especialmente a mis sinodales de tesis:

Dr. Ivan Vladimir Meza Ruiz

Dr. Gerardo Eugenio Sierra Martinez

M.I. Yukihiro Minami Koyama

Dr. Eduardo Espinosa Avila

Dra. Jimena Olveres Montiel

los cuales se tomaron su tiempo para leer mi trabajo y darme correcciones. Su atención y asesoría fue de gran utilidad para terminar este trabajo.



# Contenido

<b>1</b>	<b>Introducción</b>	<b>1</b>
<b>2</b>	<b>Antecedentes</b>	<b>3</b>
2.1	Estado del arte . . . . .	4
2.1.1	Análisis de los métodos usados . . . . .	4
2.1.2	Análisis de los corpus usados . . . . .	6
2.1.3	Análisis de resultados . . . . .	7



# Capítulo 1

## Introducción

La ironía es una figura retórica que consiste en decir lo contrario de lo que se quiere dar a entender; esta definición es a veces difícil de entender para una persona y por lo tanto es de esperarse que es más difícil de hacer entender a un sistema de cómputo. Hasta este momento, se le puede dar a una computadora un conjunto de instrucciones específicas, y si se logra definir de algún modo las intenciones, se puede hacer que una computadora entienda de forma concreta un concepto. Sin embargo, la ironía reta a la lógica y es difícil para una persona explicar si una oración es irónica o es algo literal, muchas veces esto depende del contexto. Es cuando entra la inteligencia artificial, que ayuda a no explicar cosas que no se entienden bien o que dependen de muchas condiciones y hace que el sistema computacional salte la barrera de la lógica dotándola de procesos que simulan el razonamiento humano. La inteligencia artificial se ha usado en otras tareas como conducir un automóvil, clasificar objetos, darle significado a las palabras, entre otras.

El objetivo de esta tesis es proponer un modelo de red neuronal que pueda identificar ironía en textos cortos procedentes de Twitter. Dicha solución podría ayudar a los estudios de mercado que buscan la aceptación de un producto mediante el monitoreo de las redes sociales para minar opiniones, incluso en campañas políticas, comerciales o movimientos sociales ya que predeciría la opinión real de una persona sobre cierto tema. A su vez tiene conexión con otros problemas como la búsqueda de significados, minería de opiniones, modelos para detectar contradicciones, entre otros.

El problema antes descrito ha sido explorado por comunidades de científicos e investigadores alrededor del mundo, en la Tabla 1.1 se pueden ver algunos de los trabajos que se han hecho anteriormente:

Como se ha podido ver, las redes neuronales se han ocupado para esta tarea, sin embargo muchos sugieren que estas implementaciones pueden mejorarse, las redes neuronales se han utilizado en la universidad de Standford para crear el pie de foto de imágenes, Google las ocupa para reconocer los números de las casa en las fotos que toman sus automóviles y ubicarlas en el mapa, en Mountain View las ocupan para mejorar el reconocimiento de voz de Android, ahorrar electricidad en sus servidores, y esto es solo una pequeña parte de sus aplicaciones. Por lo que es una motivación para probar como se desempeñan las redes neuronales en esta tarea.

Investigador/es	Artículo	Métodos
Mihalcea, Strappara & Pulman	Learning to laugh (automatically): Computational models for humor recognition. Computational intelligence	Naive Bayes SVM
Tsur & Davidov	Semisupervised recognition of sarcastic sentences in twitter and amazon	k-NN
Sounjanya Poria, Erik Cambria, Devamanyu Hazarika	A deeper look into sarcastic tweets using deep convolutional neural networks	CNN

Tabla 1.1: Algunos trabajos sobre ironía y/o sarcasmo

La descripción del método es la siguiente:

- Obtención del corpus
- Preprocesamiento de los documentos que componen el corpus (embedding, tokenización, normalización, lematización, conversión a vectores), explorar las diversas herramientas que ya existen y destacar la mejor de todas.
- Análisis de la red neuronal que mejor se adapta al problema, crear un conjunto de caminos viables para elegir los que podrían dar mejores resultados
- Diseño de los experimentos, diseñar las redes neuronales que resolverán la tarea
- Evaluación, elegir las métricas que mejor describan el desempeño del modelo
- Conclusiones, se dará una explicación de los resultados, se analizará las oportunidades de crecimiento, lo que se hizo bien y lo que se hizo mal.

Debido a que las redes neuronales han tenido un desempeño excelente en una gran variedad de aplicaciones es de esperarse buenos resultados, en caso de que los resultados sean negativos sería muy importante revisar los diferentes parámetros de la red neuronal que se pueden cambiar, por ejemplo el número de capas ocultas, el número de nodos de cada capa, la normalización de los datos, la iniciación pseudoaleatoria de los pesos.

Para finalizar la estructura de esta tesis es la siguiente: primero se presentaran algunos antecedentes y el estado del arte de la tarea que se propone, para después explicar un poco de la teoría detrás del método que se usará para resolverla, por último se obtendrán resultados que se compararán con los obtenidos en la sección de antecedentes para terminar con una conclusión y cuales podrían ser los trabajos a futuro.

En este trabajo se usó el recurso de Google, llamado Colab Research, desde el cual se puede usar un entorno de desarrollo en Python 2 o 3, usando como interfaz Jupyter. La ventaja de usar esta herramienta es que se puede acceder al hardware de procesamiento de tensores de Google, Tensor Processing Unit (TPU), los cuales por experiencia propia llegan a ser hasta 20 veces más rápido que usar una GPU. Los experimentos de esta tesis se encuentran en la siguiente liga <https://drive.google.com/open?id=1oV5X1ZlOxXT-3npxp89BRwWcmSuSbOm43>

## Capítulo 2

# Antecedentes

La ironía como un recurso lingüístico se destaca entre otras por su facilidad para satisfacer al lector, la ironía da un valor agregado a la comunicación, si aparece como sátira provoca una risa casi instantánea, si aparece como sarcasmo suele ser más hiriente, incluso suele hacernos pensar en las implicaciones de lo que nos atrevemos a decir, como en el siguiente ejemplo:

*“(...)En otra ocasión Borges firmaba ejemplares en una librería del Centro. Un joven se acercó con Ficciones y le dijo: ‘Maestro, usted es inmortal’... Borges le contestó: ‘Vamos, hombre, no hay por qué ser tan pesimista’.”* Romero (2012)

Este ejemplo ilustra muy bien el impacto de la ironía, de cierta forma maximiza la idea que el autor desea. Este impacto suele aportar una mayor carga de información y por lo tanto más interés en conseguirla. Ésta es una de las motivaciones que han tenido diferentes grupos de estudio para abordar la clasificación de la ironía.

Para hablar de las motivaciones que este problema ha tenido para analizarse podemos empezar por ver el trabajo de Maynard & Greenwood (2014) quienes se orientan por el análisis de sentimientos en redes sociales cuando este recurso es utilizado; para Utsumi (1995) fue uno de los primeros trabajos que se hicieron en este tema y su motivo para realizar un sistema fue para proveer de herramientas a los sistemas NLP (*Natural Language Processing*) y que pudieran manejar la ironía de manera correcta, este sistema consistía en un conjunto de reglas de emociones; Davidov *et al.* (2010) crean un sistema semi supervisado el cual tiene buen desempeño y resuelve la clasificación en inglés, algunos de sus motivos fue la monitorización de marcas, resumen de reseñas, sistemas de diálogo y proponen un marco de referencia para crear estos sistemas con detección de sarcasmo.



## 2.1. Estado del arte

El problema de la clasificación de la ironía reside en su característica de comprimir ideas en un pequeño conjunto de palabras, como en el siguiente ejemplo:

*Me encanta discutir por las mañanas por dios es algo tan :)*

Figura 2.1: Twitter id 631446828127506432

De esta pequeña frase manualmente podemos extraer las siguientes ideas: La persona no está encantada y a la persona no le gusta discutir. En este ejemplo pudimos extraer dos ideas aparte de la idea que por si sola expresa la frase, y en un contexto general ésta no tiene importancia. El siguiente ejemplo expone un caso mucho más complejo:

*Empieza un bonito día... Selectividad2015*

Figura 2.2: Twitter id 608133042348130304

Esta frase al contrario de la anterior requiere de un contexto para saber que es irónica, ya que la *Selectividad* es un examen que se aplica en España para acceder a la educación universitaria. De esta frase podemos extraer las siguientes suposiciones: La persona se siente nerviosa por el examen, la persona preferiría empezar su día con otra actividad, la selectividad es un examen difícil, etc. En este ejemplo necesitamos de un contexto que nos ayude a intuir hacia donde va dirigida la idea que se quiere comunicar y a la vez esta idea genera más ideas relacionadas con un contexto general, por ejemplo: *A nadie le gustan las pruebas, Las personas le tienen miedo al fracaso, etc.*

La extracción de información es un problema muy complejo y consiste en el estudio de un texto y la inferencia de la idea. En general la ironía interfiere en esta extracción introduciendo ruido a la inferencia, ya que aunque la ironía en forma de sarcasmo representa un pequeño porcentaje según Liu *et al.* (2007) modifica la inferencia por ser una figura lingüística que no puede ser tomada literalmente, aquí como sugerencia puede omitirse o invertirse la polaridad de la idea (si es que esto se quiere obtener). Por ejemplo en la extracción de reseñas podemos tomarlas como negativas, debido que la mayoría de las veces que se usa el sarcasmo (tipo de ironía que consiste en herir) es para dañar o para dar una mala opinión, esto dependerá del área de estudio donde se desee aplicar un modelo de extracción de información. Sin embargo la parte central de esto es la detección de la ironía.

### 2.1.1. Análisis de los métodos usados

Los métodos que han sido utilizados pueden clasificarse en las categorías que muestra la tabla 2.1

Clasificación	Artículos
Orientados a reglas	<i>Formalization and rules for recognition of satirical irony</i> Kong & Qiu (2011) <i>How to interpret irony by computer: A comprehensive framework for irony</i> Utsumi (1995)
Supervisado	<i>Making objective decisions from subjective data: Detecting irony in customers reviews (POS+features; NB,SVM,DT)</i> Reyes & Rosso (2012) <i>The perfect solution for detecting sarcasm in tweets #not (Winnow Classification)</i> Liebrecht <i>et al.</i> (2013) <i>Humans require context to infer ironic intent (so computers probably do, too) (SVM)</i> Wallace <i>et al.</i> (2014) <i>Italian irony detection in Twitter:a first approach (DT)</i> Barbieri <i>et al.</i> (2014) <i>Detecting irony on greel political Tweets: A text mining approach (J48, NB, FT, KStar, Random Forests)</i> Charalampakis <i>et al.</i> (2015) <i>Character and word baselines for irony detection in spanish short texts(SVM;RF)</i> Jasso & Meza (2016)
Semi-supervisados	<i>Semi-supervised recognition of sarcastic sentences in Twitter and Amazon (HFW,CW,KNN-like)</i> Davidov <i>et al.</i> (2010)

Tabla 2.1: Algunos de los métodos que se han usado para clasificar la ironía

#### 2.1.1.1. Orientados a reglas

En los métodos utilizados están los que requieren de la programación de reglas, estos métodos también son supervisados, pero difieren de éstos ya que requieren una mayor intervención del experto. Los sistemas basados en reglas pueden utilizar varios paradigmas como lógica difusa, lógica booleana, etc. Lo importante de estos métodos es que te permiten encontrar una respuesta clara del por qué esa muestra ha sido clasificada como irónica o no. Para estos métodos suelen utilizarse herramientas como etiquetas Part of speech (POS) que ayudan a la clasificación de las palabras dentro de una clase como adjetivos, verbos, adverbios, sustantivos, etc. Esto sirve, por ejemplo, para dar una descripción de como se puede encontrar una sentencia irónica. Una desventaja de estos métodos es que se necesita un experto para la generación de reglas, aunque hay algunos casos de sistemas que pueden generar reglas de manera automática Mitra & Pal (1995) como estos sistemas hay varios. La desventaja es que en estos casos si los sistemas son muy sensibles pueden generar reglas muy generales, que expliquen cosas comunes del idioma e irrelevantes para la tarea, o muy específicas de una oración en particular Kotsiantis *et al.* (2007). Como se puede ver es un método poderoso para la interacción con una persona, y tal vez de más ayuda cuando se quiere modelar una lengua de manera analítica. Sin embargo carece de adaptabilidad, ya que si cambiamos el idioma o el contexto, como lo hacen las redes sociales, todo el sistema debe volver a crearse. Los principales expositores de este método son Kong & Qiu (2011), para el idioma chino y Utsumi (1995), para el idioma inglés.

#### 2.1.1.2. Supervisados

En esta categoría está el método que se propone en esta tesis, los métodos supervisados son aquellos que requieren de datos de entrenamiento etiquetados para poder encontrar el modelo adecuado, los datos deben ser etiquetados por expertos los cuales puedan distinguir a que clase pertenece una muestra, estos métodos

suelen necesitar muchas muestras y un tiempo de entrenamiento considerable. La eficiencia del modelo va a depender de la destreza de los expertos para clasificar las muestras por lo que aún es susceptible a fallos. En esta categoría se encuentran métodos que usan POS para encontrar características de las muestras, como lo hace Reyes & Rosso (2012) después de este preproceso se pasa a un clasificador como Support Vector Machine (SVM) , Naive Bayes (NB) y Decision Tree (DT), en el caso de Reyes & Rosso (2012) se extrajeron 6 características de las muestras: n-grams, POS, funny profiling, positive/negative profiling, affective profiling y pleasantness profiling. Una vez con las características y una función de mapeo, que transforme las palabras a este conjunto de características, se puede usar un clasificador como los antes mencionados. Aquí las diferentes aproximaciones se concentran en el idioma ingles, griego, italiano y español, Charalampakis *et al.* (2015), Barbieri *et al.* (2014) y Jasso & Meza (2016) respectivamente, el presente trabajo se centrará en la detección de ironía en español como Jasso & Meza (2016).

### 2.1.1.3. Semi-supervisados

Los métodos semi-supervisados son aquellos que no requieren la intervención de los expertos. A esta clasificación pertenece únicamente un trabajo previo, el trabajo de Davidov *et al.* (2010) que consiste en dos fases: adquisición de patrones de un conjunto pequeño de muestras etiquetadas del 1 al 5, de nada sarcástico a completamente sarcástico, y la fase de clasificación. Para obtener los patrones del conjunto de muestras etiquetadas se clasifican las palabras en High Frequency Words (HFW) y Content Words (CW), lo cual denota cuales son las palabras más relevantes, dependiendo de un umbral de aparición para la HFW es  $F_H$  y CW es  $F_C$ , al momento de extraer los patrones se ven más o menos así:

<p>[COMPANY] CW does not CW much does not CW much about CW CW or</p>
--

Tabla 2.2: Ejemplo de como se ve un patrón en este sistema, como se puede ver los dos ejemplos pueden aparecer simultáneamente en un misma oración, notesé que las palabras [COMPANY] y “.”son HFW. Extraído de Davidov *et al.* (2010)

Estos patrones sirven para después convertir las muestras del conjunto no etiquetado, en vectores que describan la posición de ese patrón en un espacio de características. La clasificación es tan fácil como medir la distancia euclidiana, contar cuantos son no sarcásticos y cuantos son sarcásticos en su vecindad, y asignar una clase dependiendo del promedio de su distancia. Así si la muestra está rodeada de muestras sarcásticas será sarcástica completamente y cuando esté entre un conjunto de muestras que algunas son sarcásticas y algunas no, se le asignará una clase porcentual, que indica que tan sarcástica es.

### 2.1.2. Análisis de los corpus usados

El corpus en general no cambia mucho de una investigación a otra, como muestra la tabla 2.3, la mayoría de los corpus están compuestos por textos provenientes de Twitter ya que provee herramientas simples<sup>1</sup> para extraer tweets automáticamente. También suelen utilizarse corpus de Amazon ya que tienen una Application

---

<sup>1</sup><https://developer.twitter.com/>

Programming Interface (API) para extraer textos<sup>1</sup>. Hablando de los idiomas donde se han aplicado está el chino, inglés, holandés, italiano, griego y por último el español, idioma del corpus de este estudio.

Otro ámbito importante de estos experimentos es que consideran un corpus no balanceado, debido a que de acuerdo con Reyes & Rosso (2012), Jasso & Meza (2016) y Barbieri *et al.* (2014), muestran una clara diferencia entre la cantidad de muestras irónicas o sarcásticas de las que no, por lo que nos permitimos inferir que la proporción del uso de la ironía o sarcasmo es de aproximadamente el 12 %. Resulta importante conocer esto ya que nos aporta información sobre la naturaleza del problema y nos ayuda a decidir mejor como es que debemos de abordarlo.

En la mayoría de las investigaciones que obtuvieron su propio corpus, éste debió pasar por un proceso de normalización donde se removían datos irrelevantes como links de internet, caracteres especiales que no aportan información como '@' y '#' como lo hizo Jasso & Meza (2016). Muchas veces se utiliza un conjunto de palabras que se ignoran llamadas *stopwords* como en el caso de Reyes & Rosso (2012). En adición a esto, algunos autores añadieron el uso de *Term Frequency-Inverse Document Frequency*, que ayuda a medir la importancia de una palabra en un documento, dependiendo de como aparece en el documento y que tanto aparece en el corpus completo, como el caso de Reyes & Rosso (2012), Wallace *et al.* (2015) y Bamman & Smith (2015). Muchas veces los métodos de extracción de información también atrapan documentos repetidos y éstos deben reducirse a mano o crear algún sistema que los detecte y los borre como en el caso de Charalampakis *et al.* (2015) y Reyes & Rosso (2012). En el caso de Ptáček *et al.* (2014) obtuvieron características del texto como los n-grams, etiquetas POS, patrones con HFW, otras como emoticones, signos de puntuación y otras características de los caracteres como el número de mayúsculas, minúsculas, etc., todo esto lo aplicó a un corpus en checo, de 325 muestras sarcásticas y 6,675 no sarcásticas, y otro en inglés, el corpus en inglés balanceado fue de 50,000 cada clase y el no balanceado fue de 25,000 sarcásticos y 75,000 no sarcásticos.

### 2.1.3. Análisis de resultados

Para hablar de los resultados que otros investigadores han tenido nos referiremos a la tabla 2.4 donde se muestra como la mayoría de los trabajos previos han hecho sus experimentos sobre los datos de Twitter. Además la mayoría han usado un método de aprendizaje supervisado y solo uno semi-supervisado Davidov *et al.* (2010), podemos ver también que la distribución de datos está sesgada a la poca aparición del sarcasmo/ironía, como lo menciona Liu *et al.* (2007) para su corpus de Amazon, esto parece aplicar también para Twitter.

Después de ver más de cerca los resultados que reportan estos investigadores, se puede notar que los mejores resultados parecen ser los de Poria *et al.* (2016) cuando usa CNN combinado con SVM y obtiene un valor de F-score de 0.948 que comparado con la mayoría es más grande, este estudio fue la continuación del trabajo de Ptáček *et al.* (2014) el cual consistía en obtener principalmente las características más relevantes como los n-grams, etiquetas POS, patrones con HFW, otras como emoticones, signos de puntuación y otras características de los caracteres como el número de mayúsculas, minúsculas, etc., con todo esto se usaron dos métodos SVM y Maximum Entropy Modeling (MaxEnt) el cuál parece funcionar muy bien para el inglés. Sin embargo para el checo no es así ya que SVM tiene mayor puntaje en F-score (0.582) lo cual es muy bajo, esto

---

<sup>1</sup><https://developer.amazon.com/services-and-apis>

Artículo	Fuente	Idioma	Tamaño
Semi-supervised Recognition of Sarcastic Sentences in Twitter and Amazon Davidov <i>et al.</i> (2010)	Twitter & Amazon	Inglés	5.9 millones tweets & 66,000 reseñas
Making Objective Decisions from Subjective Data: Detecting Irony in Customers Reviews Reyes & Rosso (2012)	Amazon, Slashdot & TripAdvisor	Inglés	3,163 → 2,861 reseñas
The prefect solution for detecting sarcasm in tweets #not Liebrecht <i>et al.</i> (2013)	Twitter	Holandés	3.3 millones de tweets
Humans Require Context to Infer Ironic Intent (so Computers Probably do, too) Wallace <i>et al.</i> (2014)	Reddit	Inglés	3,020 comentarios
Italian Irony Detection in Twitter: a First Approach Barbieri <i>et al.</i> (2014)	Twitter	Italiano	25,450 tweets (12.5 %/87.5 %)
Detecting Irony on Greek Political Tweets: A Text Mining Approach Charalampakis <i>et al.</i> (2015)	Twitter	Griego	61,427 tweets → 44,438 tweets
Character and Word Baselines for Irony Detection in Spanish Short Texts Jasso & Meza (2016)	Twitter	Español(30/70)	14, 511 tweets irónicos & 33, 859 tweets no irónicos
SOUKHRIA: Towards an Irony Detection System for Arabic in Social Media Karoui <i>et al.</i> (2017)	Twitter	Arabe	1,733 tweets irónicos & 3,746 tweets no irónicos <sup>1</sup>
Sarcasm Detection on Czech and English Twitter Ptáček <i>et al.</i> (2014)	Twitter	Checo/Inglés	Checo 325/6,675, Inglés (50/50) y (25/75)

Tabla 2.3: Descripción de los corpus de experimentos anteriores

Investigadores	P	R	A	F1	Detalles
Davidov <i>et al.</i> (2010)	0.912	0.756	0.947	0.827	Corpus no balanceado (471/5020), método KNN-like, datos de Amazon
Reyes & Rosso (2012)	0.771	0.725	0.7575	0.747	Corpus balanceado, método SVM, datos de Amazon
Liebrecht <i>et al.</i> (2013)	NA	0.75	NA	NA	Corpus balanceado, método Winnow, datos de Twitter
Liebrecht <i>et al.</i> (2013)	NA	0.56	NA	NA	Corpus no balanceado (25/75), método Winnow, datos de Twitter
Barbieri <i>et al.</i> (2014)	0.75	0.76	NA	0.76	Corpus no balanceado (12/88), método DT, datos de Twitter
Ptáček <i>et al.</i> (2014)	NA	NA	NA	0.923	Corpus no balanceado (25/75), método MaxEnt, datos de Twitter inglés
Ptáček <i>et al.</i> (2014)	NA	NA	NA	0.582	Corpus no balanceado (325/6675), método SVM, datos de Twitter checo
Poria <i>et al.</i> (2016)	NA	NA	NA	0.948	Corpus no balanceado (25/75), método CNN-SVM, datos de Twitter
Jasso & Meza (2016)	NA	NA	NA	0.80	Análisis hecho a nivel carácter con un corpus no balanceado, método SVM, datos de Twitter
Jasso & Meza (2016)	NA	NA	NA	0.80	Análisis hecho a nivel carácter con un corpus no balanceado, método RF, datos de Twitter

Tabla 2.4: Algunos resultados de otros investigadores, P = precisión, R = recall, A = Accuaracy, F1 = F-score

según ellos fue por que algunas muestras necesitaban conocimiento general, que con 6,700 muestras no fueron suficientes para obtener, por otro lado en inglés como ya se mencionó sirvió mejor MaxEnt y dio un 0.923 de F-score, esto puede indicar que como Domingos (2012) menciona hay dos formas de mejorar el desempeño de esta tarea, una es conseguir más datos y otra en mejorar o encontrar un algoritmo que requiera menos datos.

Respecto a los demás podemos destacar el trabajo de Reyes & Rosso (2012) quienes principalmente describen una forma de como obtener el corpus y el trabajo de Jasso & Meza (2016) que obtuvo mejores resultados con un análisis a nivel de carácter, con un corpus no balanceado (30/70), tal vez debido a que en Twitter es necesario explotar más el potencial de los caracteres y suelen verse abreviaciones del texto, como por ejemplo “que” pasa a ser “q” cuando el límite de caracteres se ha alcanzado en un tweet.



# Bibliografía

- BAMMAN, D. & SMITH, N.A. Contextualized Sarcasm Detection on Twitter. *ICWSM* **2**:15 (2015)
- BANIK, P.P., SAHA, R., & KIM, K.D. LED color prediction using a boosting neural network model for a visual-MIMO system. *Optics Communications* (2018)
- BARBIERI, F. & SAGGION, H. Automatic Detection of Irony and Humour in Twitter. En *ICCC*, págs. 155–162 (2014)
- BARBIERI, F., RONZANO, F., & SAGGION, H. Italian irony detection in twitter: a first approach. En *The First Italian Conference on Computational Linguistics CLiC-it*, pág. 28 (2014)
- BHATIA, R. Is neural networks the greatest algorithm of all times (2017)
- CARDELLINO, C. Spanish Billion Words Corpus and Embeddings (2016)
- CHARALAMPAKIS, B., SPATHIS, D., KOUSLIS, E., & KERMANIDIS, K. Detecting irony on greek political tweets: A text mining approach. En *Proceedings of the 16th International Conference on Engineering Applications of Neural Networks (INNS)*, pág. 17. ACM (2015)
- DAVIDOV, D., TSUR, O., & RAPPOPORT, A. Semi-supervised recognition of sarcastic sentences in twitter and amazon. En *Proceedings of the fourteenth conference on computational natural language learning*, págs. 107–116. Association for Computational Linguistics (2010)
- DOMINGOS, P. A few useful things to know about machine learning. *Communications of the ACM* **55**(10):78–87 (2012)
- FAWCETT, T. An introduction to ROC analysis. *Pattern recognition letters* **27**(8):861–874 (2006)
- FILATOVA, E. Irony and Sarcasm: Corpus Generation and Analysis Using Crowdsourcing. En *LREC*, págs. 392–398. Citeseer (2012)
- FRENDIA, S. Ironic gestures and tones in twitter. En *4th Italian Conference on Computational Linguistics, CLiC-it 2017*, tomo 2006, págs. 1–6. CEUR-WS (2017)



- GOLDBERG, Y. A primer on neural network models for natural language processing. *Journal of Artificial Intelligence Research* **57**:345–420 (2016)
- HUANG, H.H., CHEN, C.C., & CHEN, H.H. Disambiguating false-alarm hashtag usages in tweets for irony detection. En *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, tomo 2, págs. 771–777 (2018)
- JASSO, G.L. & MEZA, I.R. Character and word baselines systems for irony detection in Spanish short texts. *Procesamiento del Lenguaje Natural* **56**:41–48 (2016)
- JOSHI, A., BHATTACHARYYA, P., & CARMAN, M.J. Automatic sarcasm detection: A survey. *ACM Computing Surveys (CSUR)* **50**(5):73 (2017)
- KAR, A.K. Bio inspired computing—A review of algorithms and scope of applications. *Expert Systems with Applications* **59**:20–32 (2016)
- KAROUI, J., ZITOUNE, F.B., & MORICEAU, V. SOUKHRIA: Towards an Irony Detection System for Arabic in Social Media. *Procedia Computer Science* **117**:161–168 (2017)
- KINGMA, D.P. & BA, J. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980* (2014)
- KONG, L. & QIU, L. Formalization and Rules for Recognition of Satirical Irony. En *Asian Language Processing (IALP), 2011 International Conference on*, págs. 135–138. IEEE (2011)
- KOTSIANTIS, S.B., ZAHARAKIS, I., & PINTELAS, P. Supervised machine learning: A review of classification techniques. *Emerging artificial intelligence applications in computer engineering* **160**:3–24 (2007)
- LIEBRECHT, C., KUNNEMAN, F., & VAN DEN BOSCH, A. The perfect solution for detecting sarcasm in tweets# not. *Proceedings of the 4th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis* (2013)
- LIU, J., CAO, Y., LIN, C.Y., HUANG, Y., & ZHOU, M. Low-quality product review detection in opinion summarization. En *Proceedings of the 2007 Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning (EMNLP-CoNLL)* (2007)
- MAYNARD, D. & GREENWOOD, M.A. Who cares about sarcastic tweets? investigating the impact of sarcasm on sentiment analysis. En *LREC 2014 Proceedings*. ELRA (2014)
- MCCULLOCH, W.S. & PITTS, W. A logical calculus of the ideas immanent in nervous activity. *The bulletin of mathematical biophysics* **5**(4):115–133 (1943)
- MITRA, S. & PAL, S.K. Fuzzy multi-layer perceptron, inferencing and rule generation. *IEEE Transactions on Neural Networks* **6**(1):51–63 (1995)

- NAFIS, S.T.O.P.T. & KHANNA, S. An improved method for detection of satire from user-generated content. *International Journal of Computer Science and Information Technologies*, Vol. 6 (2015)
- NOZZA, D., FERSINI, E., & MESSINA, E. Unsupervised Irony Detection: A Probabilistic Model with Word Embeddings. En *KDIR*, págs. 68–76 (2016)
- OLAH, C. Understanding LSTM Networks (2015)
- PORIA, S., CAMBRIA, E., HAZARIKA, D., & VIJ, P. A deeper look into sarcastic tweets using deep convolutional neural networks. *arXiv preprint arXiv:1610.08815* (2016)
- PTÁČEK, T., HABERNAL, I., & HONG, J. Sarcasm detection on czech and english twitter. En *Proceedings of COLING 2014, the 25th International Conference on Computational Linguistics: Technical Papers*, págs. 213–223 (2014)
- REDDY, D.R., BHARAMA, P., & GOVINDARAJULU, K. Performance Analysis of Domestic Refrigerator Using Hydrocarbon Refrigerant Mixtures with ANN. *Numerical Heat Transfer and Fluid Flow: Select Proceedings of NHTFF 2018* pág. 113 (2019)
- REYES, A. & ROSSO, P. Making objective decisions from subjective data: Detecting irony in customer reviews. *Decision Support Systems* **53**(4):754–760 (2012)
- ROMERO, S. Borges incorregible: sus frases más irónicas (2012)
- ROSENBLATT, F. The perceptron: a probabilistic model for information storage and organization in the brain. *Psychological review* **65**(6):386 (1958)
- RUDER, S. An overview of gradient descent optimization algorithms. *CoRR* **abs/1609.04747** (2016). 1609.04747
- RUMELHART, D.E., HINTON, G.E., & WILLIAMS, R.J. Learning representations by back-propagating errors. *nature* **323**(6088):533 (1986)
- SANTOS, A.L. Assessing the culture of fruit farmers from Calvillo, Aguascalientes, Mexico with an artificial neural network: An approximation of sustainable land management. *Environmental Science & Policy* **92**:311–322 (2019)
- UTSUMI, A. How to interpret irony by computer: A comprehensive framework for irony. En *Proceedings of the International Conference “Recent Advances in NLP*, págs. 315–321 (1995)
- UTSUMI, A. A unified theory of irony and its computational formalization. En *Proceedings of the 16th conference on Computational linguistics-Volume 2*, págs. 962–967. Association for Computational Linguistics (1996)

- WALLACE, B.C., KERTZ, L., CHARNIAK, E. *et al.* Humans require context to infer ironic intent (so computers probably do, too). En *Proceedings of the 52nd Annual Meeting of the Association for Computational Linguistics (Volume 2: Short Papers)*, tomo 2, págs. 512–516 (2014)
- WALLACE, B.C., CHARNIAK, E. *et al.* Sparse, contextually informed models for irony detection: Exploiting user communities, entities and sentiment. En *Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*, tomo 1, págs. 1035–1044 (2015)

